AgentHelpLearn

Cơ chế hoạt động và căn cứ thiết kế

Báo cáo kỹ thuật

Tháng 10 năm 2026

Mục lục

Cách đọc báo cáo **3**

1 Toàn bộ cơ chế hoạt động **4**
1.1 App làm gì . . . 4
1.2 Ba tầng: màn hình, máy chủ, kho . . . 4
1.2.1 Tài khoản . . . 4
1.2.2 Hai loại cấu hình . . . 4
1.3 Lõi harness: mọi lời gọi AI đi qua đây . . . 5
1.3.1 Agent, việc và hợp đồng . . . 5
1.3.2 Bốn nhóm việc . . . 5
1.3.3 Vòng xử lý của một lời gọi . . . 5
1.3.4 Các mã lỗi đóng . . . 6
1.4 Bốn nguyên tắc lặp lại ở mọi harness . . . 6
1.5 Một lần dùng app, từ đầu tới cuối . . . 6
1.6 Căn cứ nghiên cứu cho các nguyên tắc chung . . . 7

2 Nạp và đọc sách **8**
2.1 Harness này làm gì . . . 8
2.2 Quy trình . . . 8
2.3 Số trang in . . . 9
2.4 Tách bài tập . . . 9
2.5 Căn cứ thiết kế . . . 10

3 Hỏi đáp có nguồn **11**
3.1 Harness này làm gì . . . 11
3.2 Đường đi của một câu hỏi . . . 11
3.3 Từ dấu nguồn tới số trang in . . . 11
3.4 Học sinh thấy gì . . . 12
3.5 Căn cứ nghiên cứu . . . 13

4 Chấm bài tập **14**
4.1 Harness này làm gì . . . 14
4.2 Luồng một lượt chấm . . . 14
4.3 Học sinh thấy gì . . . 15
4.4 Phần đã dựng và phần mới thiết kế . . . 15
4.5 Căn cứ nghiên cứu . . . 16

5 Mức nắm và ngân hàng câu hỏi **18**
5.1 Sổ mức nắm: harness này làm gì . . . 18
5.1.1 Luật ghi bằng chứng . . . 18
5.1.2 Bốn chỉ số, gợi ý học tiếp, hướng học . . . 18
5.1.3 Căn cứ nghiên cứu cho sổ mức nắm . . . 19
5.2 Ngân hàng câu hỏi: harness này làm gì . . . 20
5.2.1 Ba đường đưa câu vào . . . 20
5.2.2 Chuỗi cổng của một câu . . . 20
5.2.3 Căn cứ cho bộ lọc câu hỏi . . . 21

A Phụ lục kỹ thuật **23**
A.1 Lõi harness . . . 23
A.2 Nạp và đọc sách . . . 23
A.3 Hỏi đáp có nguồn . . . 24
A.4 Chấm bài tập . . . 24
A.5 Mức nắm và ngân hàng câu hỏi . . . 24
A.6 Chỗ tài liệu lệch code . . . 24

Cách đọc báo cáo

Báo cáo giải thích AgentHelpLearn hoạt động thế nào và vì sao từng lựa chọn thiết kế có cơ sở. Phần thân (chương 1 tới chương 5) viết cho giáo viên và hội đồng đề tài: mỗi chương là một *harness*, tức một chuỗi bước có AI và chương trình phối hợp, gồm sơ đồ luồng, từng bước, người học thấy gì, phần đã dựng và phần mới thiết kế, giới hạn hôm nay, và căn cứ nghiên cứu. Phụ lục A dành cho kỹ sư, ghi vị trí trong code của từng bước.

Ba quy ước xuyên suốt:

- **Code thắng tài liệu.** Báo cáo tả những gì code làm hôm nay; chỗ tài liệu thiết kế nói khác được ghi riêng.
- **Số đo của nghiên cứu không phải số đo của app.** Mỗi con số trích từ một nghiên cứu được ghi kèm điều kiện dữ liệu của nó (ngôn ngữ, bậc học, cỡ mẫu). App chưa có số đo hiệu quả riêng.
- **Hộp "Giới hạn hôm nay"** ở mỗi chương ghi những điều app chưa làm được, để người đọc không hiểu quá những gì app làm.

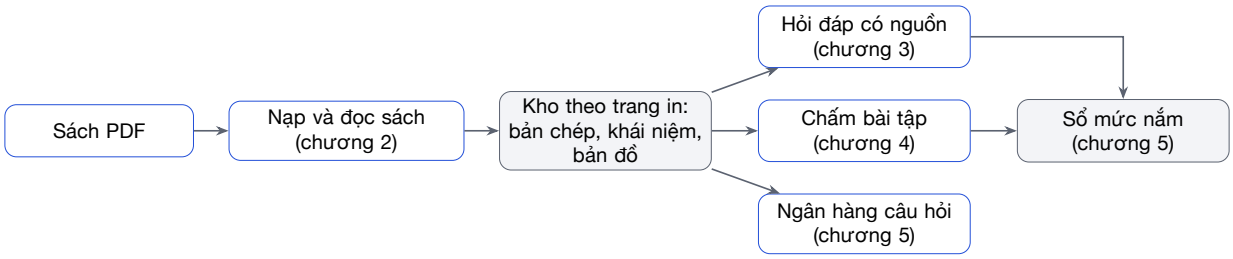
Trong các sơ đồ, ô viền xanh là bước có gọi AI; ô nền xám là bước do chương trình làm, không gọi AI.

Chương 1

Toàn bộ cơ chế hoạt động

1.1 App làm gì

AgentHelpLearn biến một quyển sách giáo khoa dạng PDF thành một kho tri thức có thể tra lại tới từng trang in, rồi dùng kho đó để hỏi đáp, chấm bài, theo dõi mức nắm và lọc câu luyện. Mọi việc cần đọc hiểu đều do các *agent* AI làm; mọi việc kiểm tra được bằng chương trình thì chương trình làm.



Hình 1.1: Năm harness và dòng dữ liệu giữa chúng. Ô nền xám là dữ liệu.

1.2 Ba tầng: màn hình, máy chủ, kho

- **Màn hình** gồm các màn đăng nhập, thiết lập AI, tài liệu, xử lý, bản đồ, hỏi, bài tập, cá nhân hoá và ngân hàng câu hỏi. Màn mở đầu tự chuyển người dùng tới bước còn thiếu: chưa thiết lập AI thì sang thiết lập, chưa có tài liệu thì sang tài liệu, chưa xử lý thì sang xử lý.
- **Máy chủ** trả mọi phản hồi theo một khuôn chung: thành công kèm dữ liệu, hoặc một mã lỗi đóng.
- **Kho** là thư mục riêng của từng tài khoản. Nguồn sự thật là các *tệp*: bản chép từng trang, bài viết cho từng khái niệm, vector, sổ mức nắm. Cơ sở dữ liệu chỉ giữ tài khoản và phiên đăng nhập.

1.2.1 Tài khoản

Mỗi tài khoản có kho riêng. Mật khẩu được băm, máy chủ không giữ mật khẩu hay mã phiên thô. Phiên đăng nhập sống 30 ngày, đổi mật khẩu thì mọi phiên đang mở bị đóng. Máy chủ có thể đòi *mã mời* khi đăng ký; không đặt mã mời thì ai cũng đăng ký được. Trên máy phát triển có sẵn một tài khoản mẫu.

1.2.2 Hai loại cấu hình

Cấu hình	Phạm vi	Chở gì
Chọn AI cho từng việc	Cả máy chủ	Nhà cung cấp và model cho từng việc, chỉ chở *tên* biến chứa khoá
Khoá truy cập	Từng tài khoản	Giá trị khoá. Chỉ ghi được, không có đường đọc ra; mỗi lời gọi đọc lại nên dùng được ngay
Tuỳ chọn xử lý	Từng tài khoản	Các thông số như trần chi phí, số vòng tìm khi hỏi

Bảng 1.1: Ai chọn model, ai giữ khoá.

1.3 Lõi harness: mọi lời gọi AI đi qua đây

1.3.1 Agent, việc và hợp đồng

Mỗi lời gọi AI có một *hợp đồng*: một tệp lời dặn (prompt) ghi rõ việc, phiên bản, agent, và một khuôn kết quả (schema). Agent được đặt tên theo dạng *vai.việc*, với bảy vai: *reader* (đọc trang), *extractor* (rút ý), *verifier* (kiểm, chấm), *clusterer* (xếp nhóm), *answerer* (trả lời, giải), *generator* (soạn đề) và *cross-checker* (đối chiếu nguồn ngoài). Mỗi kết quả mang theo nguồn gốc: nhà cung cấp, model, prompt và phiên bản đã sinh ra nó.

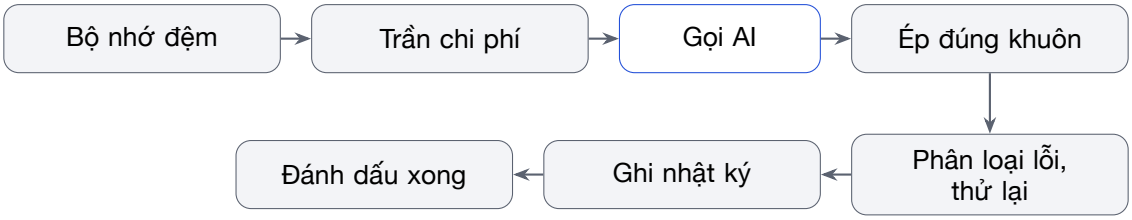
1.3.2 Bốn nhóm việc

Chương trình xin một *nhóm việc*, không xin một hãng AI cụ thể:

- **Đọc ảnh** (read_image): nhìn ảnh trang sách, chép chữ, khoanh hình.
- **Viết chữ** (generate_text): trả lời, rút ý, soạn đề.
- **Soát và chấm** (judge): kiểm ý đã rút, chấm bài, kiểm câu hỏi.
- **Biến chữ thành số** (embed): tạo vector để tìm phần sách gần nghĩa.

Mỗi nhóm có hai bậc, *rẻ* và *mạnh*. Màn Chọn AI gán model cho từng nhóm và bậc. Đổi hãng chỉ cần đổi cấu hình, không phải sửa code. Đọc sách chạy bậc rẻ; chấm bài chạy bậc mạnh.

1.3.3 Vòng xử lý của một lời gọi



Hình 1.2: Mọi lời gọi AI đi cùng một vòng.

1. **Bộ nhớ đệm.** Cùng prompt, cùng phiên bản, cùng đầu vào thì dùng lại kết quả cũ, không tốn chi phí.
2. **Trần chi phí.** Mỗi bước có một trần lượng xử lý (token). Chạm trần thì việc đó dừng với mã *vượt trần*, các việc khác vẫn chạy. Trần tính trên lượng thật do nhà cung cấp báo về.
3. **Ép đúng khuôn.** Kết quả phải đúng schema. Chương trình thử phục hồi JSON hỏng (bỏ phần suy nghĩ, bỏ rào code, cắt phần thừa, bỏ dấu phẩy treo) mà không gọi lại AI; còn hỏng thì gửi lại cho AI kèm nguyên văn lỗi, tổng cộng tối đa 3 lời gọi. Luật: không sửa dữ liệu cho vừa khuôn.
4. **Phân loại lỗi và thử lại.** Lỗi được chia năm loại: AI từ chối (không thử lại), quá tải (thử lại có chờ), lỗi mạng, đầu vào quá dài (chia nhỏ rồi thử), sai khuôn. Bên ngoài, cả năm quy về một mã *nhà cung cấp từ chối*.
5. **Nhật ký.** Mỗi lời gọi ghi một dòng; bộ ghi chặn mọi trường trông như khoá.
6. **Đánh dấu xong.** Chỉ đánh dấu khi thành công, nên tắt máy giữa chừng rồi chạy lại không gọi lặp.

1.3.4 Các mã lỗi đóng

Mọi lỗi người dùng thấy thuộc một tập mã đóng, mỗi mã kèm việc nên làm tiếp: chưa khảo sát tài liệu, kho chưa qua kiểm, kho đã cũ, vượt trần chi phí, nhà cung cấp từ chối, cấu hình chỉ đọc, không tìm thấy. Không có thông báo lỗi dạng chữ tự do.

1.4 Bốn nguyên tắc lặp lại ở mọi harness

Chương trình kiểm trước, AI kiểm sau.
Những gì tính được bằng chương trình (câu trích có trên trang không, đáp án trắc nghiệm có khớp không, đẳng thức số có đúng không) thì không hỏi AI. Hỏi AI một câu đã biết là trả tiền cho nó, và còn có thể nhận câu trả lời sai.

Không chắc thì nói không chắc.
App có những lối ra riêng cho chỗ không đủ căn cứ: *Cần xem lại* khi chấm bài, *Không tìm thấy* khi hỏi, *Chờ soát* và *không kiểm được* khi lọc câu hỏi.

Mọi câu neo về trang in.
Khái niệm, câu trả lời, câu trích trong thang chấm đều mang số trang in trên giấy, và được dò lại trên bản chép của trang đó.

Không để AI tự kiểm việc của chính nó trong cùng một lượt.
Bước kiểm là một lượt gọi riêng, ngữ cảnh trắng, và phải trích bằng chứng có thật.

1.5 Một lần dùng app, từ đầu tới cuối

1. Người dùng đăng nhập; máy chủ chọn đúng kho của tài khoản.
2. Lần đầu: chọn AI cho từng nhóm việc (chung cả máy chủ) và dán khoá truy cập (riêng tài khoản).
3. Tải sách PDF lên.
4. AI đọc mục lục, rồi đọc từng bài, rút khái niệm, một lượt khác kiểm khái niệm, xếp vào môn và chương (chương 2).
5. Học sinh xem bản đồ kiến thức, hỏi đáp có số trang (chương 3), làm bài và được chấm (chương 4), xem mức nắm và thêm câu luyện (chương 5).

Giới hạn hôm nay

- **Năm trong chín mục ở màn Tuỳ chọn xử lý chưa được code nào đọc**: số vòng gọi công cụ, cỡ lô gom khái niệm, luật chọn trang đọc hai lần, lớp nguồn tham khảo, và cách trả lời khi sách với nguồn ngoài khác nhau. Màn vẫn cho sửa cả chín.
- **Bước kiểm nhiều phiếu chưa chạy thật.** Hàm kiểm với số phiếu lẻ có trong code nhưng không đường chạy nào gọi tới; phép kiểm đang chạy là một lượt cho mỗi bài học. Bước kiểm dùng cùng nhà cung cấp và cùng họ model với bước sinh.
- Bộ nhớ đệm không tính tên model, nên đổi model mà giữ nguyên bậc có thể vẫn nhận kết quả cũ.
- Chưa có số đo nào trên tiếng Việt và trên model đang dùng, và chưa có bộ dữ liệu có nhãn do người gán.

1.6 Căn cứ nghiên cứu cho các nguyên tắc chung

Kiểm bằng một lượt riêng, có tài liệu tham chiếu. Zheng et al. [62] đo GPT-4 làm người chấm: khớp người 85% (giữa người với người 81%), nhưng chỉ nhất quán 65% khi đảo thứ tự hai câu trả lời, và cho qua đáp án toán sai ở 14 trên 20 ca; có đáp án tham chiếu thì còn 3 trên 20. Huang et al. [26] cho thấy không có phản hồi từ bên ngoài thì mô hình khó tự sửa suy luận. Panickssery et al. [44] cho thấy mô hình nhận ra văn của chính mình thì càng thiên vị nó.

Nhiều phiếu, hội đồng chấm. Verga et al. [52] cho một hội đồng ba mô hình khác họ khớp người tốt hơn GPT-4 đứng một mình, ví dụ κ 0,763 so với 0,627. Chen and Wan [15] chấm 5 lượt rồi lấy đa số; xem lại 10–15% số bài có độ phân tán cao nhất thì bắt được khoảng 40% lỗi (vật lý đại học). Ở chiều ngược lại, Lee et al. [36] thấy bỏ phiếu không thắng cách chọn một lượt tốt nhất, nên số phiếu để là thông số.

Phần so được thì giao cho chương trình. Yamauchi et al. [57]: kiểm khuôn bằng thuật toán đúng 100%, bằng mô hình ngôn ngữ đúng 91,7% (12 bài toán lớp 8 ở Nhật). Zhao et al. [60]: một câu mở đầu rỗng đủ làm GPT-4o chấm nhầm 53,6% trên GSM8K.

Hỏi từng phần thay vì hỏi cả bài. Banjade et al. [1] cho GPT-4 chấm bài thật: phán cả bài đúng 40–41%, so từng câu đúng 94% (50 bài tự giải thích mã nguồn). Bước kiểm khái niệm của app hỏi bốn câu đóng riêng rẽ theo tinh thần này; đây là suy luận của báo cáo, tài liệu nghiên cứu của dự án dùng nguồn này cho phần chấm.

Không kiểm được thì bỏ, chấp nhận mất dữ liệu. PRM800K [37] có nhãn trung tính cho bước mơ hồ. Kortemeyer et al. [32] bỏ các bài chấm dao động, còn 84% dữ liệu; Zhang et al. [59] thấy lọc theo đồng thuận chỉ giữ khoảng 40%. Giá của việc không đoán là mất một phần dữ liệu.

Neo mọi câu về trang in. Nguyên tắc này xuất phát từ yêu cầu thiết kế của dự án. Các tài liệu nghiên cứu trong dự án không nêu nguồn riêng cho việc neo bằng phép dò chuỗi; khung gần nhất là yêu cầu *quy được về nguồn* của Rashkin et al. [45] (chương 3).

Chương 2

Nạp và đọc sách

2.1 Harness này làm gì

Harness này nhận một quyển sách PDF, thường là sách giáo khoa scan, và biến nó thành một kho tra lại được:

- bản chép chữ của từng trang, đặt tên theo **số trang in trên giấy**;
- hình trên trang, cắt rời thành ảnh;
- mỗi khái niệm sách dạy thành một bài viết ngắn, neo về đúng các trang in đã dạy nó;
- mỗi khái niệm một vector để so độ gần nghĩa;
- khái niệm được xếp vào Môn › Lĩnh vực › Chương;
- quan hệ "bài về B có nhắc tới khái niệm A".

Bài tập trong sách (Ví dụ, Luyện tập, Vận dụng, đề cuối bài) được tách thẳng từ bản chép trang bằng chương trình. Luật xuyên suốt: chỉ ghi điều kiểm lại được trên trang in.

2.2 Quy trình

1. **Tìm mục lục.** Một lượt AI đọc ảnh của vài trang đầu và vài trang cuối sách (người dùng chọn số trang), trả về danh sách chương, bài và các cặp "trang trong tệp, số in trên giấy".
2. **Tính lệch trang.** Chương trình tính độ lệch giữa số trang trong tệp và số in trên giấy, chia sách thành chương và bài, mỗi chương một khoảng trang khép kín.
3. **Đọc từng trang.** Với mỗi bài, một lượt AI đọc ảnh từng trang và trả ba thứ: chữ, khung các hình, và loại trang (lý thuyết, bài tập, hỗn hợp). Chương trình cắt hình, ghi bản chép, xếp trang lý thuyết và trang bài tập riêng. Trang đã đọc với đúng phiên bản prompt thì lần sau dùng lại, không tốn chi phí.
4. **Rút khái niệm.** Một lượt AI đọc *chỉ các trang lý thuyết* của bài và rút ra khái niệm: tên, phần tóm tắt, các mục, các trang được dẫn, và liên kết tới khái niệm liên quan.
5. **Chương trình lọc.** Bỏ khái niệm không tên; bỏ trang dẫn nằm ngoài các trang đã đọc; bỏ khái niệm chỉ dẫn về trang bài tập.
6. **AI thứ hai kiểm khái niệm.** Một lượt kiểm riêng hỏi bốn câu đóng cho mỗi khái niệm: có đúng là một khái niệm không; có thật trong trang không; đã đủ ý chưa; tên đã đúng chưa. Phán quyết chung do chương trình tính: trượt một câu là bỏ khái niệm. Kèm theo là một phép đếm bằng chương trình tìm các mục có số hiệu mà không khái niệm nào chạm tới, chỉ để cảnh báo.
7. **Ghi bài viết và vector.** Khái niệm trùng tên với bài đã có thì được gộp, không ghi đè.
8. **Xếp nhóm.** Ba lượt AI: xếp khái niệm vào lĩnh vực; gán Môn › Lĩnh vực cho từng chương, chọn từ một danh mục đóng theo chương trình giáo dục phổ thông 2018; tìm các tên chủ đề đồng nghĩa. Tên lạ ngoài danh mục thành "Khác".
9. **Dựng bản đồ khi mở xem.** Liên kết "B nhắc tới A" được dựng bằng cách dò tên khái niệm A trong bài viết của B, không lưu sẵn.



Hình 2.1: Nạp một quyển sách. Ô nền xám do chương trình làm. Các bài học chạy song song.

2.3 Số trang in

Kho dùng hai hệ đếm: số trang trong tệp để đọc ảnh, và **số in trên giấy** cho mọi neo. AI chỉ báo con số nó thấy; chương trình tính độ lệch bằng trung vị, ưu tiên các trang đầu tệp (một tệp 905 trang có hai dãy đánh số làm trung vị cả hai đầu lệch tới 805). Nếu PDF có lớp chữ, các con số in trong lớp chữ *thắng* con số của AI theo bỏ phiếu. Khi đọc từng trang, nếu số AI đọc ra khác số kho chờ và lớp chữ chứng minh độ lệch sai thì cả lượt xử lý dừng với lỗi. Sách scan không có lớp chữ thì phải tin con số AI đọc.

2.4 Tách bài tập

Bài tập được tách từ bản chép trang bằng mẫu nhận diện, không gọi AI: đề dạng "số chương.số", các mục *Ví dụ*, *Luyện tập*, *Vận dụng* xen giữa lý thuyết, và các ý a), b). Mục *Hoạt động* bị loại. Ba nguồn lời giải không bao giờ trộn: lời giải in trong sách, lời giải AI viết, và bài giải của học sinh. Trên sách Toán 10 tập một (Kết nối tri thức) chương trình tách được 238 mục, trong đó 55 mục có lời giải in.

Giới hạn hôm nay

- **Mẫu tách bài tập mới hợp sách Toán của bộ Kết nối tri thức.** Trên sách Hoá 10 cùng bộ, cả 61 mục tách được đều là Ví dụ; sách Lí 10 chỉ ra 9 mục.
- **Bản chép trang có thể lệch bản in** (đổi dấu, mất chữ số, đảo chiều bất đẳng thức), và chưa có bước đọc lần hai để bắt lỗi chép, dù bước đó đã có trong thiết kế.
- **Bước rút và bước kiểm khái niệm đang dùng cùng một model** ở cấu hình hiện tại, nên lý do tách hai nhóm việc chưa thành hiện thực.
- **Một trang đọc hỏng làm dừng cả lượt xử lý**; phần đã ghi vẫn còn và được dùng lại ở lượt sau.
- Bước kiểm khái niệm không thấy được thứ bị bỏ sót; phép đếm chỗ bỏ sót dựa vào kiểu đánh số mục của sách đại học, sách phổ thông ít dùng.
- Liên kết "B nhắc tới A" dựa vào dò tên, nên tên ngắn dễ khớp nhầm và khái niệm đồng nghĩa không được gộp.
- Các bài học chạy song song không giới hạn số luồng.

2.5 Căn cứ thiết kế

Các tài liệu nghiên cứu của dự án viết cho phần chấm bài và phần mức nắm, không nối nguồn nào trực tiếp với phần đọc sách. Những nối kết dưới đây là suy luận của báo cáo này.

Kiểm khái niệm bằng một lượt riêng, nhóm việc riêng. Lý do tách bước kiểm (nhóm *soát và chấm*) khỏi bước rút (nhóm *viết chữ*) là để có thể dùng model khác: Panickssery et al. [44] cho thấy mô hình thiên vị văn của chính mình, và hội đồng nhiều mô hình khác họ của Verga et al. [52] khớp người tốt hơn một mô hình đứng một mình. Trang sách đóng vai phản hồi bên ngoài mà Huang et al. [26] cho là cần thiết để mô hình sửa được lỗi.

Bốn câu đóng, phán quyết do chương trình tính. Cách chia lời kiểm thành các câu có hoặc không giống thang chấm nhị phân của Yamauchi et al. [57] ($\kappa \approx 0{,}63$ với người, toán lớp 8, 12 bài) và thang ba mục có hoặc không của Chen and Wan [15] (trùng người 70–80%, vật lý đại học). Việc buộc bằng chứng chép nguyên văn rồi so chuỗi giống ý *trích bằng chứng trước, chấm sau* của AutoSCORE [53], vốn nâng độ khớp QWK từ 0,540 lên 0,629 trên bộ ASAP tiếng Anh.

Liên kết có hướng giữa các khái niệm. Liên kết "B nhắc tới A" gần với quan hệ *cần biết trước* mà Chen et al. [14] đưa vào việc theo dõi người học; app suy liên kết từ việc nhắc tên chứ chưa xác định quan hệ cần biết trước thật.

Danh mục môn và lĩnh vực. Danh mục đóng Môn › Lĩnh vực theo các mạch kiến thức của chương trình giáo dục phổ thông 2018 [7–9].

Cấu trúc kho. Cây "bản chép trang không sửa → bài viết cho từng khái niệm → mục lục và nhật ký" theo mẫu *LLM wiki* của Andrej Karpathy, được đóng gói thành một skill mã nguồn mở.

Chương 3

Hỏi đáp có nguồn

3.1 Harness này làm gì

Học sinh hỏi một câu về nội dung sách. App chỉ được trả lời bằng những ý đã có trong kho dựng từ sách (chương 2). Mỗi câu trong câu trả lời phải mang một dấu nguồn trỏ về một trang in. Câu nào không chỉ ra được nguồn thì bị gỡ trước khi học sinh thấy. Nếu kho không có gì đủ khớp, app nói thẳng là không tìm thấy chứ không đoán. Lời chào hỏi thông thường thì được trả lời như một cuộc trò chuyện, không tra kho.

3.2 Đường đi của một câu hỏi

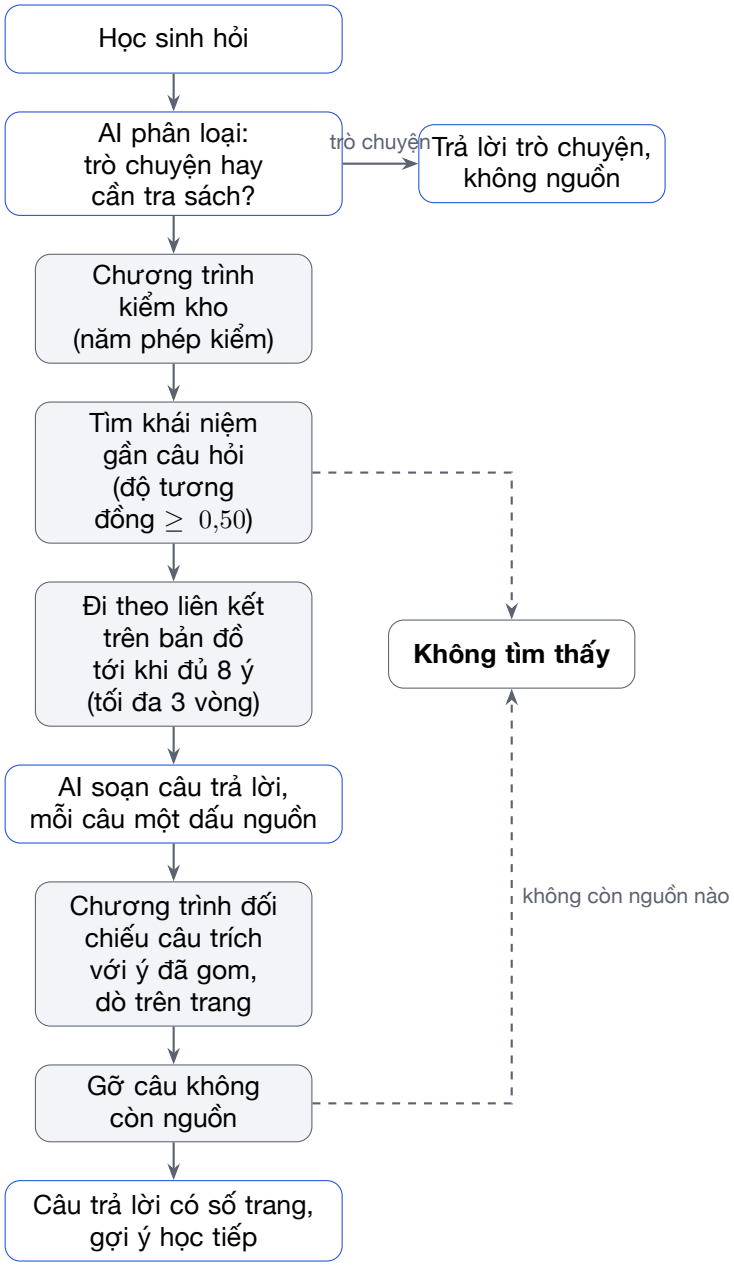
1. **Phân loại.** Một lượt AI nhỏ xem cả đoạn hội thoại và quyết định câu này là trò chuyện hay cần tra sách. Prompt dặn: khi nghi ngờ thì coi là cần tra.
2. **Kiểm kho.** Trước khi tra, chương trình chạy năm phép kiểm kho: mỗi khái niệm có trang nguồn và trang đó có thật, liên kết trỏ tới khái niệm có thật, mọi khái niệm có vector, không trùng tên. Hỏng phép nào là dừng.
3. **Tìm khái niệm gần câu hỏi.** Câu hỏi được biến thành vector rồi so với vector của từng khái niệm. Chỉ khái niệm có độ tương đồng từ 0,50 trở lên mới được dùng, tối đa 5 khái niệm. Không khái niệm nào đạt ngưỡng thì trả *Không tìm thấy*.
4. **Đi theo bản đồ.** Từ các khái niệm đó, app mở rộng sang khái niệm kề trên bản đồ kiến thức, mỗi vòng một lớp, và dừng khi đã gom đủ 8 ý hoặc đã đi đủ 3 vòng.
5. **Soạn câu trả lời.** AI chỉ được dùng các ý đã gom. Mỗi câu phải có dấu nguồn, kèm câu trích chép nguyên văn. Nếu các nguồn nói khác nhau, AI phải trình bày cả hai phía.
6. **Kiểm nguồn.** Chương trình đối chiếu từng câu trích với các ý đã gom; câu trích không khớp ý nào bị loại, đây là chốt chặn trích dẫn bịa. Sau đó nó dò câu trích trên chữ của từng trang để lấy số trang in.
7. **Gỡ câu không nguồn.** Câu nào không còn dấu nguồn hợp lệ bị gỡ. Không còn nguồn nào thì trả *Không tìm thấy*, kể cả khi AI đã viết ra một câu trả lời.
8. **Ghi lại.** Khái niệm được trích trong câu trả lời nhận bằng chứng *đã hỏi*, đề xuất mức *Nhận biết*. App gợi ý tối đa 3 khái niệm kề mà học sinh chưa nắm, khái niệm ở trang sớm hơn đứng trước.

3.3 Từ dấu nguồn tới số trang in

Mỗi khái niệm trong kho được ghi kèm các trang sách nó xuất hiện. Khi AI trích một câu, chương trình thử dò câu đó trên chữ của trang mà AI khai, rồi lần lượt các trang khác của khái niệm. Trang đầu tiên dò thấy là trang được in ra. Học sinh bấm số trang để mở ảnh trang gốc; nếu một lượt AI đọc ảnh khoanh được hình minh hoạ, ảnh được cắt vào hình đó.

Số trang này có thể chưa chính xác trong ba trường hợp:

- Ý trong kho là lời AI viết lại từ sách, nên câu trích thường không dò thấy nguyên văn trên trang. Khi đó app vẫn giữ câu trích và ghi *trang đầu tiên* mà khái niệm xuất hiện, chưa chắc là trang chứa ý.
- Phép dò bỏ dấu tiếng Việt để chịu được lỗi chép, nên hai chữ khác nghĩa có thể bị coi là trùng.
- Chữ đem ra dò là bản chép trang do AI đọc ảnh tạo ra, không phải trang giấy.



Hình 3.1: Một câu hỏi. Ô nền xám do chương trình làm. Mũi tên đứt là đường ra *Không tìm thấy*.

Phép dò chỉ chứng minh câu trích có trên trang. Nó không chứng minh lời diễn đạt quanh dấu nguồn nói đúng điều câu trích nói.

3.4 Học sinh thấy gì

Câu trả lời gồm các đoạn có dấu nguồn bấm được, ảnh trang gốc của từng trang đã trích, và dòng *Nguồn đã trích*. Khi một đoạn có nguồn từ hai tài liệu, màn hiện hai cột ngang nhau. Có dải cảnh báo khi app đã đi hết số vòng cho phép mà vẫn còn khái niệm kề chưa mở. Phía dưới là khối *Giảng giải*: vài câu diễn đạt lại bằng lời dễ hiểu, không có dấu nguồn. Học sinh chọn chế độ *Nhanh*, hoặc *Mạnh* cho câu khó (chậm và tốn chi phí hơn).

Giới hạn hôm nay

- Số trang có thể là trang đầu của khái niệm thay vì trang chứa ý, và app chưa đánh dấu câu trích nào đi đường này.
- Khối *Giảng giải* không qua bước kiểm nào; luật "không thêm sự kiện" chỉ nằm trong lời dặn AI.
- AI chỉ thấy câu hỏi cuối, nên câu hỏi nối tiếp kiểu "còn cái kia thì sao?" tìm kém.
- Dòng thông báo số đoạn bị ẩn gần như luôn bằng 0, vì phía máy chủ đã gỡ câu từ trước mà không báo số câu.
- Prompt chưa có luật cấm giải hộ bài tập.
- Chính sách trả lời theo mức tài liệu (*theo sách* cho sách phổ thông) đã có trên màn Tuỳ chọn xử lý nhưng chưa được nối vào đường hỏi đáp.
- Ngưỡng 0,50, 5 khái niệm, 8 ý là hằng số kỹ thuật, mới đặt dựa trên đo giữa các khái niệm với nhau, chưa đo trên câu hỏi thật.

3.5 Căn cứ nghiên cứu

Truy hồi theo đồ thị. Cách tìm khái niệm gần câu hỏi rồi mở rộng theo liên kết trên bản đồ giống chế độ *tìm cục bộ* của GraphRAG [22]: dựng đồ thị thực thể từ tài liệu, rồi trả lời một câu hỏi về một chỗ cụ thể bằng cách xuất phát từ các thực thể liên quan và lấy thêm vùng lân cận của chúng. Khác ở chỗ app dừng theo số ý đã gom và số vòng, và mỗi ý mang số trang.

Câu trả lời có trích dẫn, gỡ câu không nguồn. ALCE [24] đặt yêu cầu mô hình viết câu trả lời kèm trích dẫn tới đoạn nguồn và chấm riêng việc mỗi câu có được nguồn của nó hỗ trợ hay không. Khung AIS [45] định nghĩa một câu là *quy được về nguồn* khi một người đọc nguồn có thể nói "theo nguồn này thì…". App áp yêu cầu đó bằng chương trình: câu không mang được nguồn bị gỡ. Khác ở chỗ phép kiểm của app là dò chuỗi, chưa kiểm sự kéo theo như AIS.

Kiểm bằng chương trình thay vì để AI tự kiểm. Huang et al. [26] cho thấy không có phản hồi từ bên ngoài thì mô hình ngôn ngữ khó tự sửa suy luận, có khi còn tệ hơn. Việc đối chiếu câu trích bằng chương trình là phản hồi bên ngoài. Chain-of-Verification [20] là một hướng khác: mô hình tự sinh câu hỏi kiểm rồi trả lời lại; trên bài liệt kê thực thể Wikidata nó nâng độ chính xác từ 0,17 lên 0,36. App không dùng cách này.

Khối Giảng giải, và vì sao nó nên đổi. Tự giải thích giúp học: Bisra et al. [4] tổng hợp 69 hệ số và được $g = 0{,}55$. Nhưng chính tổng hợp này cho thấy người học tự giải thích hơn đọc lời giải thích của người dạy ($g = 0{,}35$, 6 hệ số), dù lời giải thích có sẵn vẫn giữ được một phần lợi ích. Theo khung ICAP [16], đọc lời giảng có sẵn là học thụ động hoặc chủ động, còn tự giảng là mức cao hơn. Wittwer and Renkl [56] thấy lời giảng của người dạy thường không cải thiện việc học, và Lachner et al. [35] thấy chỉ việc tự giải thích mới giúp chuyển giao. Tên gọi "kỹ thuật Feynman" không có nghiên cứu mạnh đứng riêng [46]. Vì vậy khối *Giảng giải* nên được hiểu là *lời giảng của máy*, và hướng sửa có căn cứ là để học sinh tự giảng trước rồi mới mở lời giảng của máy.

Rào chắn không giải hộ. Bastani et al. [2] thử trên khoảng 1 000 học sinh cấp 3 ở Thổ Nhĩ Kỳ: có GPT-4 lúc luyện thì điểm luyện tăng 48% (bản thường) và 127% (bản gia sư có rào chắn), nhưng khi bỏ công cụ thì nhóm dùng bản thường kém nhóm đối chứng 17%, còn nhóm có rào chắn không kém. Rào chắn ở đó là không đưa lời giải. Đường hỏi đáp của app chưa có rào chắn này, nên không thể nói app "có bằng chứng tránh tác hại".

Chương 4

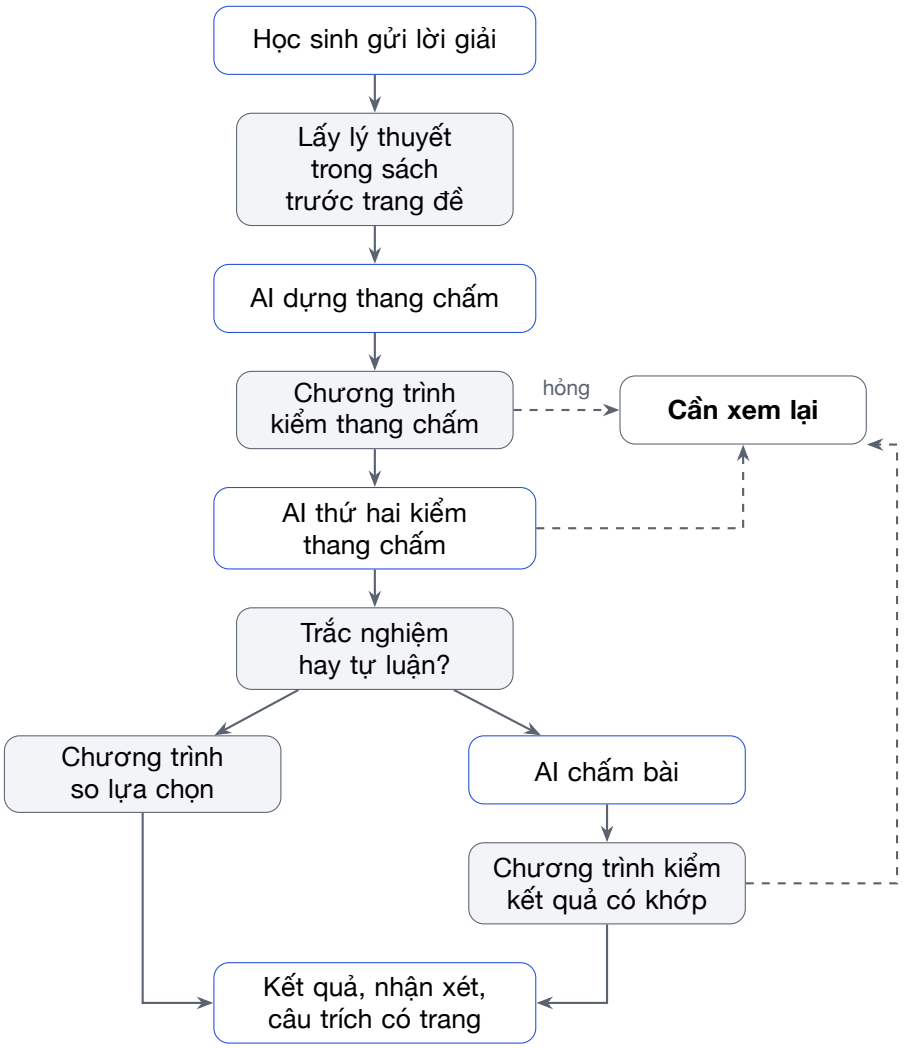
Chấm bài tập

4.1 Harness này làm gì

Học sinh chọn một bài trong sách hoặc một bài do máy soạn, viết lời giải, rồi bấm *Chấm bài*. Máy trả về bốn thứ: kết luận (*Đúng*, *Đúng một phần*, *Chưa đúng* hoặc *Cần xem lại*), điểm trên 100, phần làm tốt và phần cần sửa, kèm câu trích nguyên văn từ sách có số trang in.

Nguyên tắc của harness này là **sách là đáp án, kiến thức nền của AI thì không**. Trước khi đọc bài của học sinh, máy dựng một *thang chấm* (bảng đáp án theo từng ý) từ phần lý thuyết trong sách. Thang chấm được kiểm hai lần: một lần bằng chương trình, một lần bằng một lượt AI riêng. Chỉ khi qua cả hai lần kiểm, bài mới được chấm. Chỗ nào máy không chắc, nó trả *Cần xem lại* chứ không đoán.

4.2 Luồng một lượt chấm



Hình 4.1: Một lượt chấm. Ô nền xám do chương trình làm, không gọi AI. Mũi tên đứt là đường ra *Cần xem lại*.

1. **Lấy ngữ cảnh từ sách.** Chương trình lấy các trang từ đầu bài học tới ngay trước trang có đề. Với bài do máy soạn hoặc câu của ngân hàng, nó lấy chính các trang nguồn mà đề mang theo.
2. **AI dựng thang chấm.** Thang chấm ghi bài là trắc nghiệm hay tự luận, đáp án mong đợi, và từng ý cần có. Mỗi ý kèm một câu trích nguyên văn và số trang in của câu đó.
3. **Chương trình kiểm thang chấm.** Thang chấm bị loại nếu AI tự khai rằng sách không đủ để chấm, nếu đáp án có lựa chọn không có trong đề, hoặc nếu một câu trích không tìm thấy nguyên văn *đúng trên trang in đã ghi*. Với trắc nghiệm, các ý phải phủ đủ mọi lựa chọn và không được mâu thuẫn với đáp án.
4. **AI thứ hai kiểm thang chấm.** Đây là một lượt gọi riêng. Nó được dặn rằng nó không phải tác giả của thang chấm, phải kiểm theo lối phản biện, và không được tự sửa. Nó từ chối thì kết quả là *Cần xem lại*.
5. **Chấm.** Nếu là trắc nghiệm và học sinh chỉ ghi các chữ cái lựa chọn, chương trình so hai tập lựa chọn mà không gọi AI. Còn lại, một AI chấm bài theo thang chấm đã kiểm. Trước khi gửi, chương trình gỡ các mốc đặc biệt khỏi bài làm, để học sinh không chèn được lệnh cho AI.
6. **Chương trình kiểm kết quả chấm.** Kết quả bị loại nếu kết luận và điểm mâu thuẫn (*Đúng* mà dưới 70 điểm, *Chưa đúng* mà trên 40 điểm), nếu *Đúng* mà vẫn còn chỗ cần sửa, nếu một câu trích không nằm trong thang chấm đã kiểm, hoặc nếu bài làm quá ngắn mà vẫn được chấm đúng.
7. **Ghi lại và xét mức nắm.** Một bài *tự luận* được chấm *Đúng* đề xuất mức *Vận dụng* cho các khái niệm mà bài chạm tới. Mọi kết quả khác chỉ đề xuất mức *Nhận biết* (chương 5).

Khi nhà cung cấp AI từ chối trả lời hoặc chạm trần lượng xử lý, máy báo *Chưa chấm được* và cho thử lại. Trường hợp này không bị tính là *Cần xem lại*.

4.3 Học sinh thấy gì

Màn Bài tập hiện kết luận và điểm, một đoạn nhận xét, mục *Phần làm tốt*, mục *Cần sửa*, và mục *Nguồn trong sách*: từng câu trích trong ngoặc kép, kèm liên kết tới đúng trang in. Sửa bài sau khi chấm thì kết quả cũ bị ẩn đi và màn nhắc chấm lại. Lời giải in trong sách và lời giải do AI viết nằm trong mục đóng sẵn; lời giải của AI có cảnh báo *chưa được kiểm tra*.

4.4 Phần đã dựng và phần mới thiết kế

Hạng mục	Trạng thái
Thang chấm từ sách, kiểm bằng chương trình, kiểm bằng AI thứ hai, so trắc nghiệm bằng chương trình, AI chấm tự luận, kiểm kết quả, *Cần xem lại*, luật đề xuất mức	Đã dựng
Chấm *từng bước*, dùng phần mềm tính toán (sympy) kiểm từng phép biến đổi	Chỉ có thiết kế
Chấm lời tự giải thích theo năm mức hiểu	Chỉ có thiết kế
Ba lượt chấm độc lập, phải nhất trí mới giữ *Đúng*	Chỉ có thiết kế
Kiểm thang chấm bằng một AI của hãng khác	Chưa làm

Bảng 4.1: Phần nào đã có trong code, phần nào mới nằm trong tài liệu thiết kế.

Phần mềm tính toán sympy có trong app, nhưng chỉ dùng ở bộ lọc câu hỏi (chương 5), không dùng khi chấm bài.

Giới hạn hôm nay

- **Ảnh bài viết tay được lưu nhưng không được chấm.** Máy chỉ chấm phần chữ.
- **Đáp án do AI dựng có thể sai.** Việc dò câu trích chỉ chứng minh câu đó có thật trên trang, không chứng minh kết luận rút ra từ nó là đúng. Người kiểm lại thang chấm cũng là AI, cùng nhà cung cấp.
- **Lời giải in trong sách chưa được đưa vào thang chấm**, và ngữ cảnh dừng trước trang đề, nên phần lý thuyết in cùng trang với đề bị bỏ sót.
- **Chấm cả bài trong một lượt, chưa chấm từng bước.** Một kết luận *Đúng* từ một lượt chấm đã đủ để đề xuất mức *Vận dụng*.
- **Bài do máy soạn chưa được kiểm trước khi dùng**, nhưng vẫn được tính làm bằng chứng lên mức.
- **Các phép kiểm của chương trình đo tính nhất quán, không đo độ chính xác.** Chưa có số đo nào trên bài toán tiếng Việt hay trên model đang dùng.

4.5 Căn cứ nghiên cứu

Các số dưới đây là số đo của từng nghiên cứu, trên dữ liệu và model của nghiên cứu đó. Chúng cho thấy lựa chọn thiết kế có cơ sở, không phải số đo của app.

Có đáp án tham chiếu từ sách trước khi chấm. Zheng et al. [62] cho GPT-4 chấm đáp án toán sai: nó cho qua 14 trên 20 ca; thêm chuỗi suy luận còn 6 trên 20; có đáp án tham chiếu còn 3 trên 20, tức từ 70% xuống 15%. Điều kiện: chỉ 10 câu toán, so cặp, judge là GPT-4. Daheim et al. [19] đưa lời giải mẫu cho GPT-3.5 khi kiểm bài toán lời văn tiếng Anh: F1 khi phán cả bài tăng từ 0,59 lên 0,97, còn micro F1 khi tìm bước sai chỉ tăng từ 0,42 lên 0,61. Thang chấm của app đóng vai đáp án tham chiếu đó, nhưng chưa dùng lời giải in trong sách. Huang et al. [26] cho thấy không có phản hồi từ bên ngoài thì mô hình ngôn ngữ khó tự sửa suy luận; câu trích từ sách là phản hồi bên ngoài ấy. Kim et al. [30] cho máy chấm một thang có mô tả từng mức kèm đáp án mẫu và đạt tương quan Pearson 0,897 với người (GPT-4 đạt 0,882), trong bối cảnh đánh giá chung chứ không riêng giáo dục.

Phần nào so được thì giao cho chương trình. Ngoài số liệu của Zheng et al. [62], Zhao et al. [60] chỉ ra rằng chỉ cần mở đầu bài bằng một câu rỗng kiểu *Let's solve this problem step by step.* là GPT-4o chấm nhầm 53,6% trên GSM8K và 42,6% trên MATH. Yamauchi et al. [57] kiểm khuôn đầu ra của AI chấm bằng thuật toán và đúng 100%, trong khi kiểm bằng mô hình ngôn ngữ đúng 91,7%; thang chấm nhị phân của họ khớp người ở mức $\kappa \approx 0{,}63$, so với 0,67 giữa hai người chấm. Điều kiện: toán lớp 8 ở Nhật, chỉ 12 bài.

Kiểm thang chấm bằng một lượt độc lập, và chỗ còn thiếu. Verga et al. [52] cho thấy một hội đồng ba mô hình khác họ khớp người tốt hơn GPT-4 đứng một mình (κ 0,763 so với 0,627). Panickssery et al. [44] cho thấy mô hình càng nhận ra văn của chính mình thì càng thiên vị nó. Hai nguồn này là lý do nên kiểm bằng một mô hình khác họ; app chưa làm việc này.

Không chắc thì trả *Cần xem lại*. Bộ dữ liệu PRM800K của Lightman et al. [37] gán cho mỗi bước giải nhãn đúng, sai hoặc *trung tính* cho chỗ mơ hồ, trên 800 nghìn nhãn bước. Kết quả *Cần xem lại* giữ cùng tinh thần: không ép phải phán.

Vì sao chấm đúng cả bài chưa đủ. Theo Zheng et al. [61], tỉ lệ lời giải có đáp số đúng mà có bước sai là 3,5% ở GSM8K, 18,8% ở MATH, 32,2% ở OlympiadBench và 51,8% ở Omni-MATH. Luong et al. [38] thấy bộ chấm khớp người ở cấp tổng ($r = 0{,}96$) nhưng ở cấp từng bài, trên 1 000 chứng minh, độ chính xác cao nhất chỉ 54,0%. Đây là lý do chấm từng bước nằm trong thiết kế, và là lý do một kết luận *Đúng* đơn lẻ chưa nên là bằng chứng mạnh.

Chưa chấm ảnh viết tay. Caraeni et al. [13] cho GPT-4o chấm ảnh bài làm, có đáp án và thang chấm, và đạt độ chính xác 0,4667 trên 18 sinh viên. Khâu chuyển ảnh sang chữ là chỗ hỏng lớn nhất.

Phản hồi gồm phần làm tốt, phần sửa và nguồn. Wisniewski et al. [55] tổng hợp 435 nghiên cứu: phản hồi giàu thông tin có $d = 0{,}99$, khen hay phạt đơn thuần chỉ $d = 0{,}24$. Van der Kleij et al. [51], với phản hồi trên máy tính (40 nghiên cứu): phản hồi chi tiết đạt 0,49, chỉ báo đúng sai đạt 0,05. Ở chiều ngược lại, Kluger and DeNisi [31] thấy hơn một phần ba số can thiệp phản hồi làm kết quả *giảm*. Riêng việc kèm số trang trong phản hồi thì chưa có thực nghiệm nào trong các nguồn đã đọc.

Đặt việc làm bài vào trung tâm. Roediger and Karpicke [47]: sau 5 phút nhóm đọc lại nhớ tốt hơn, nhưng sau 2 ngày và 1 tuần nhóm đã làm bài kiểm tra nhớ tốt hơn rõ rệt. Yang et al. [58] tổng hợp 222 nghiên cứu trong lớp học thật với 48 478 học sinh: $g = 0{,}499$, và hiệu ứng phụ thuộc vào việc có phản hồi hay không. Kang et al. [28]: khi có phản hồi sửa sai, câu trả lời ngắn giúp nhớ tốt nhất sau 3 ngày. Chỉ bài tự luận mới mở mức *Vận dụng* vì lý do *độ hợp lệ của bằng chứng*: chọn đúng một lựa chọn không cho thấy đường đi của lời giải.

Bài do máy soạn. Christ et al. [17] thấy khoảng 21% đề toán do GPT-4 soạn trượt ít nhất một tiêu chí chất lượng. Vì vậy đề do máy soạn cần được kiểm trước khi dùng làm bằng chứng lên mức; app chưa làm bước này.

Chương 5

Mức nắm và ngân hàng câu hỏi

Chương này gồm hai harness gắn với nhau: sổ mức nắm của từng học sinh, và bộ lọc đưa câu hỏi mới vào ngân hàng câu của từng khái niệm.

5.1 Sổ mức nắm: harness này làm gì

App giữ cho mỗi học sinh một sổ ghi mức nắm của từng khái niệm. Sổ dùng vào ba việc: chỉnh giọng câu trả lời, gợi ý học tiếp, và tô sáng bản đồ kiến thức. Sổ **không bao giờ là nguồn trích dẫn**. Mọi lần lên mức đều do chương trình quyết dựa trên bằng chứng đã ghi; AI không có quyền nâng mức.

Mức	Tên	Cửa để lên mức	Trạng thái
0	Chưa chạm	Mặc định	Đã dựng
1	Nhận biết	Khái niệm được trích trong một câu trả lời ở màn Hỏi	Đã dựng
2	Hiểu	Học sinh tự viết lời giải thích được chấp nhận	Chỉ có thiết kế
3	Vận dụng	Một bài *tự luận* được chấm *Đúng*	Đã dựng
4	Vận dụng cao	Lời giảng nối khái niệm này sang khái niệm khác, và liên kết đó có thật	Chỉ có thiết kế

Bảng 5.1: Năm mức nắm và cửa của từng mức.

5.1.1 Luật ghi bằng chứng

Mọi bằng chứng đi qua một hàm duy nhất, theo thứ tự:

1. Ghi một lượt chạm và ngày chạm cuối, cho mọi loại bằng chứng, kể cả lượt chỉ hỏi.
2. **Mỗi bài chỉ tính một lần.** Bài nào đã đưa khái niệm lên mức thì nộp lại không lên thêm.
3. **Ba luật chung:** không tụt mức; không nhảy mức; mỗi lượt lên nhiều nhất một mức. Ví dụ: đang ở *Nhận biết*, một bài tự luận đúng đề xuất *Vận dụng*, kết quả là *Hiểu*.
4. Chỉ khi mức đổi mới ghi một mốc vào lịch sử, kèm đường lên (hỏi, bài tập, tự đặt) và bằng chứng.

Học sinh cũng tự đặt được mức cho từng khái niệm. Mức tự đặt đi thẳng vào sổ, không qua ba luật trên, vì theo thiết kế ba luật ràng buộc bằng chứng máy thu được chứ không ràng buộc chủ nhân của sổ.

5.1.2 Bốn chỉ số, gợi ý học tiếp, hướng học

Chương trình tính bốn chỉ số cho từng khái niệm mà không gọi AI: *Đứng yên* (số ngày từ lần đổi mức cuối), *Tắc* (số lượt chạm từ lần lên mức gần nhất), *Mờ đi* (số ngày từ lần chạm cuối), và *Đường lên*.

Học tiếp gợi ý tối đa 6 khái niệm chưa chạm nằm sát những gì học sinh đã chạm trên bản đồ. Tab *Hướng học* cho học sinh chọn học *tổng hợp* hay *chuyên sâu một mảng*. Khi đã chạm đủ 8 khái niệm, app đoán hướng bằng một chỉ số *Tập trung* (1 trừ entropy chuẩn hoá của các chủ đề đã chạm): từ 0,6 trở lên là chuyên sâu, từ 0,4 trở xuống là tổng hợp, ở giữa thì không đoán. Chuyên sâu lấy tối đa 2 khái niệm mỗi chủ đề, tổng hợp lấy 1 và ưu tiên khái niệm bắc cầu giữa các chủ đề. Trên bản đồ, độ sáng của một khái niệm lấy 80% từ mức của chính nó và 20% từ trung bình các khái niệm kề.

Giới hạn hôm nay

- **Mức *Hiểu* chưa đo sự hiểu.** Cửa tự giải thích chưa dựng, nên có ba đường lên *Hiểu* mà không cần giải thích: hỏi rồi làm đúng một bài; nộp sai rồi nộp lại đúng chính bài đó; hai bài khác nhau cùng đúng.
- **App chưa đo ghi nhớ.** Mức không bao giờ tụt, và chỉ số *Mờ đi* được làm mới ngay cả bởi lượt hỏi chỉ đọc. Không có phép kiểm nào sau một khoảng trễ.
- **Mức tự đặt nằm chung với mức máy ghi**, nên không tách sạch được hai loại.
- **Mức *Vận dụng cao* hiện chỉ đạt được bằng cách tự đặt.**
- Các ngưỡng 0,4, 0,6, 8 khái niệm, tỉ lệ 80/20 và ngưỡng tô màu của các chỉ số là lựa chọn thiết kế, chưa có nguồn. Chính code ghi rằng chưa có bằng chứng ngưỡng nào đúng.

Vì vậy mức trong sổ nên được đọc là *nhật ký việc học sinh đã làm*, chưa phải phép đo sự hiểu hay sự nhớ.

5.1.3 Căn cứ nghiên cứu cho sổ mức nắm

Tên và số mức. Bốn mức Nhận biết, Thông hiểu, Vận dụng, Vận dụng cao là quy ước lâu năm ở Việt Nam. Công văn 8773 (2010) dùng ba cấp nhận biết, thông hiểu, vận dụng, trong đó vận dụng chia thấp và cao [5]. Thông tư 22/2016 định nghĩa bốn mức nhưng cho tiểu học [6]. Công văn 7991/2024 cho THCS và THPT chỉ còn ba mức Biết, Hiểu, Vận dụng [10]. Như vậy bốn mức của app là quy ước quen thuộc, không phải quy định hiện hành.

Hiểu là giải thích được, vận dụng là làm được. Bloom bản sửa đổi [33] định nghĩa *Hiểu* là xác định ý nghĩa của thông điệp dạy học, trong đó có *giải thích*, và *Vận dụng* là thực hiện một quy trình trong tình huống cụ thể. Đây là căn cứ cho cửa mức 2 (tự giải thích) và mức 3 (làm đúng bài). Cũng chính nguồn này viết rằng yêu cầu về một thứ bậc chặt đã được nới, tức đi ngược luật *không nhảy mức* của app.

Mức cao nhất là nối các ý. Thang SOLO [3] đặt mức *quan hệ* khi người học tích hợp nhiều khái niệm thành một khối có nghĩa. Webb [54] viết rằng độ sâu kiến thức gắn với số liên kết giữa các khái niệm mà người học phải tạo ra. Cửa mức 4 theo thiết kế (giảng nối hai khái niệm có liên kết thật) giống ở chỗ đó; nhưng vì liên kết đã có sẵn trên bản đồ, đây mới là chuyển giao gần.

Mức riêng cho từng khái niệm. Theo dõi kiến thức [18] ước mức nắm riêng cho từng kỹ năng và cập nhật sau mỗi lượt làm bài. App giữ ý tưởng mức riêng cho từng khái niệm, nhưng dùng luật cố định chứ không tính xác suất. Khajah et al. [29] chỉ ra rằng mô hình theo dõi kiến thức cổ điển giả định người học không quên, và phê chính giả định đó; luật *không tụt mức* của app mang cùng giả định.

Dùng quan hệ giữa các khái niệm. Chen et al. [14] đưa quan hệ *cần biết trước* giữa các khái niệm vào việc theo dõi người học. Việc app lấy các khái niệm sát vùng đã học làm gợi ý, và cho vùng lân cận sáng theo, giống ở chỗ dùng cấu trúc giữa các khái niệm; liên kết của app (bài này nhắc tới khái niệm kia) chưa phải quan hệ cần biết trước thật.

Trộn chủ đề khi gợi ý. Rohrer et al. [48] thử theo cụm trên 787 học sinh lớp 7: nhóm luyện trộn dạng bài đạt 62,17 điểm so với 37,60 ở bài kiểm tra trễ. Hướng *tổng hợp* của app trộn chủ đề theo tinh thần đó; nguồn này nói về trộn dạng bài toán, không nói về luật một khái niệm mỗi chủ đề.

Thành tích lúc luyện không phải thước đo học tập. Roediger and Karpicke [47]: sau 5 phút nhóm đọc lại nhớ tốt hơn, nhưng ở bài kiểm tra trễ nhóm đã làm bài nhớ tốt hơn rõ rệt. Bastani et al. [2]: có GPT-4 lúc luyện thì điểm luyện tăng 48% hoặc 127%, nhưng khi bỏ công cụ thì nhóm dùng bản thường kém nhóm đối chứng 17%. Đây là lý do mức trong sổ, vốn ghi từ thành tích lúc luyện, chưa được gọi là phép đo học tập.

5.2 Ngân hàng câu hỏi: harness này làm gì

Mỗi khái niệm có một ngân hàng câu luyện ngoài sách. Câu mới vào ngân hàng qua một chuỗi cổng theo nguyên tắc **rẻ trước, đắt sau; cái gì chương trình tính được thì không hỏi AI**. Rủi ro chính là *bác oan* một câu tốt, nên cổng nào thiếu căn cứ để bác thì đưa câu sang *Chờ soát* cho người xem, không loại hẳn. Hiện harness chạy cho môn Toán.

5.2.1 Ba đường đưa câu vào

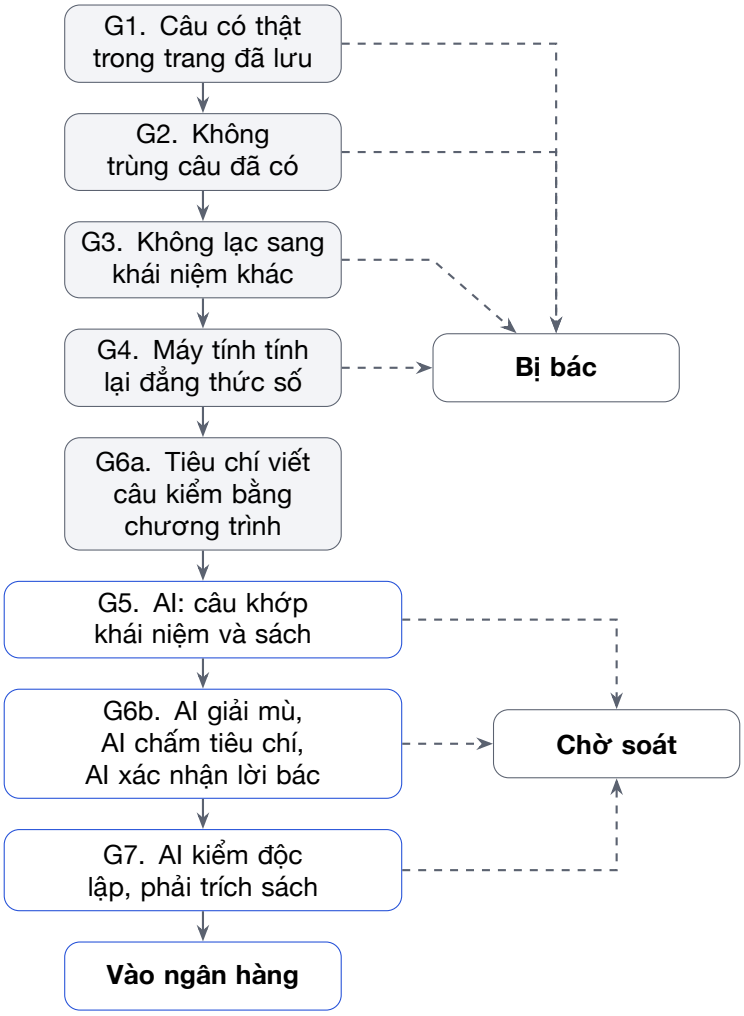
1. **Tìm trên mạng.** Với mỗi khái niệm, app gửi một lượt tìm web, tải tối đa 3 trang và lưu bản chụp bất biến của từng trang. AI chỉ trả *số dòng* của câu hỏi trong bản chụp; chương trình tự cắt chữ, nên câu đem đi kiểm đúng là câu có trên trang.
2. **AI tự soạn.** AI soạn câu, một lượt AI khác giải lại từng câu.
3. **Tải tệp lên.** PDF hoặc ảnh, tối đa 20 trang: AI đọc từng trang rồi tách câu.

Trước khi chạy, app tính dự toán chi phí và chỉ gọi AI sau khi người dùng xác nhận. Chạm trần chi phí thì câu chưa xét được ghi *chưa xét*, không vào ngân hàng.

5.2.2 Chuỗi cổng của một câu

- **G1**: câu lấy từ web phải dò thấy nguyên văn trong bản chụp trang. Không áp cho câu AI soạn hay câu tải lên, vì không có bản chụp.
- **G2**: so với đề sách, đề đã có và ngân hàng; giống từ 0,92 trở lên là trùng.
- **G3**: câu dùng tên khái niệm nằm ngoài khái niệm đang xét và các khái niệm dẫn tới nó thì bị loại.
- **G4**: phần mềm tính toán (sympy) tính lại mọi đẳng thức chỉ gồm số trong lời giải. Lệch thì bác; không có đẳng thức số nào thì ghi *không kiểm được*, không coi là đạt cũng không coi là trượt.
- **G6a, G6b**: 46 tiêu chí viết câu và khuôn đề, chia mức *bác* hoặc *chỉ cảnh báo*. Một AI giải đề mà không thấy lời giải, chương trình so đáp số với khoá; một AI chấm từng tiêu chí, mỗi lời bác phải có bằng chứng; một AI thứ ba xác nhận lời bác. Một tiêu chí chỉ được bác khi lời bác đứng vững *và* tiêu chí đã được hiệu chỉnh.
- **G7**: một lượt AI độc lập chỉ được *đồng ý* khi trích được câu từ sách; trích từ chính đề thì không tính.

Câu đạt còn được dựng sẵn thang chấm để dùng khi chấm bài (chương 4); thang chấm hỏng thì câu vẫn vào ngân hàng, chỉ không có thang chấm. Ở tab *Tra ngân hàng*, người dùng bấm *Dùng* hoặc *Bỏ* (phải ghi lý do) và gán mức độ cho từng câu.



Hình 5.1: Chuỗi cổng. Ô nền xám do chương trình làm. G5 chỉ được bác khi có lý do, có câu trích sách, và câu trích dò thấy đúng trang; thiếu một trong ba thì câu sang *Chờ soát*. G7 không có quyền bác một mình.

Giới hạn hôm nay

- **G6 hiện chưa bác câu nào.** Cả 46 tiêu chí đều chưa được hiệu chỉnh trên đề đã được Bộ duyệt, nên G6 chỉ đẩy câu nghi vấn sang *Chờ soát*.
- G2 chỉ so độ giống chuỗi, nên một đề cũ được diễn đạt lại có thể lọt. G3 trên thực tế ít bắt được câu lạc phạm vi; việc đó dựa chủ yếu vào G5.
- Câu tải lên là chữ AI chép lại từ ảnh, không có phép dò nào bắt lỗi chép.
- AI kiểm câu cùng họ với AI soạn câu, nên có rủi ro tự ưu tiên [44].
- Bộ câu vàng dùng để đo bộ lọc gồm 110 câu do agent viết và duyệt, không phải người, và không phải đề thật.
- Màn hiện tại chưa nối ngân hàng câu với sổ mức nắm.

5.2.3 Căn cứ cho bộ lọc câu hỏi

Khuôn đề và yêu cầu chung. Khuôn câu theo Quyết định 764/QĐ-BGDĐT [11]: đề Toán tốt nghiệp có 12 câu nhiều lựa chọn, 4 câu đúng/sai và 6 câu trả lời ngắn. Sách giáo khoa có câu khác khuôn, nên các

tiêu chí về số phương án chỉ ở mức cảnh báo. Yêu cầu chung của đề theo Thông tư 24/2024, Điều 5 [12]. Một nguyên tắc riêng của nhóm: tiêu chí nào bác một đề đã được Bộ duyệt là tiêu chí bác oan.

Quy tắc viết câu. Haladyna et al. [25] tổng hợp 31 hướng dẫn viết câu nhiều lựa chọn từ 27 sách và 27 nghiên cứu, chủ yếu dựa trên đồng thuận chuyên gia và dành cho đánh giá trên lớp. Một phần tiêu chí của app lấy từ đây, cùng hướng dẫn của Paniagua and Swygert [43] và Công văn 8773 [5]. Lỗi viết câu gây hại thật: Downing [21] thấy 36–65% câu trong đề của sinh viên y có lỗi; Tarrant and Ware [50] thấy 47,3% câu có lỗi trong đề điều dưỡng và học sinh giỏi bị thiệt nhiều hơn học sinh sát ngưỡng đậu. Hai nguồn này mới được đọc qua tóm tắt.

Kết hợp luật và AI để chấm chất lượng câu. Moore et al. [40] so luật viết sẵn với GPT-4 trên 200 câu do sinh viên đại học Mỹ viết: luật bắt 91% lỗi mà người đánh dấu, GPT-4 bắt 79%; bộ công cụ SAQUET của Moore et al. [41] vượt 94%. App dùng cả hai, nối tiếp nhau.

Giải mù để kiểm đáp án. Các bộ thử TreeCut [42], UMP [39], MiP [23] và UMWP [49] cho thấy mô hình ngôn ngữ hay bịa đáp số cho đề không giải được; ở ca tệ nhất của TreeCut, GPT-4o bịa tới 64%. Đây là lý do có bước AI giải đề mà không thấy lời giải rồi so đáp số. Chưa có số đo cho đề tiếng Việt.

Ba lượt AI, lượt thứ ba chỉ chạy khi có lời bác. Có đáp án tham chiếu thì tỉ lệ chấm nhầm giảm từ 70% xuống 15% [62]. Không có tham chiếu, máy chấm chỉ khớp chuyên gia ở những câu nó tự giải đúng [34]. Cách để một lượt kiểm *leo thang* thay vì tự quyết khi không chắc giống ý *trust or escalate* của Jung et al. [27].

Phụ lục A

Phụ lục kỹ thuật

Phụ lục này dành cho người làm tiếp. Mọi vị trí đọc ở nhánh `spec/kg` ngày 29/10/2026, dạng `tệp:dòng` tính từ gốc repo. Khi tài liệu và code nói khác nhau, phụ lục theo code; chỗ lệch ghi ở mục A.6.

A.1 Lõi harness

Thành phần	Vị trí
Bảng route (40 endpoint)	`kg/api/app.py:35-111`
Tài khoản, băm mật khẩu pbkdf2 200 000 vòng, phiên 30 ngày	`kg/api/tai_khoan.py:45-59, 281-300`
Mã mời `KG_MA_MOI`	`kg/api/tai_khoan.py:60, 337-351`; `serve.py:1803`
Khoá theo tài khoản (`keys.env`) thắng biến môi trường	`kg/ingest/job.py:178-197`
`POST /setup` ghi `harness.yaml`, chặn CSRF	`serve.py:667-703, 1584-1620`
Bốn capability	`kg/harness/capability.py:1-40`
Hàng đợi: cache, budget, provider, ép schema, lỗi, log, checkpoint	`kg/harness/queue.py:175-290`
Khoá cache (`prompt@version`, `capability:tier`, băm đầu vào)	`kg/harness/cache.py:57-63`
Phục hồi JSON, tối đa 3 lời gọi	`kg/harness/repair.py:8-12, 57`
Năm loại lỗi nội bộ, đường cong thử lại	`kg/harness/errors.py:58-85, 201, 238`
Kiểm độc lập nhiều phiếu (chưa có nơi gọi)	`kg/harness/verify.py:12-23, 490-533`
Bảy mã lỗi đóng	`contract/errors.json`; `job.py:252-268`

Chín thông số ở màn Tuỳ chọn xử lý. Mặc định ở `contract/config-default.json`. Code đọc: `cap_per_stage` (B, C; stage `nodes` mượn trần C, `job.py:447, 526, 756`), `max_hops` (`ask.py:691`), `survey_window` (stage B, `job.py:445`). `independent_check` chỉ được đọc trong `verify.py:533`, không ai gọi. Không code nào đọc: `tool_loop_limit`, `mention_batch`, `verify_page_rules`, `source_tier`, `policy_by_level`.

A.2 Nạp và đọc sách

Chỉ bốn stage có bộ chạy: `B`, `C`, `nodes`, `domains` (`serve.py:1026`). Backend không tự nối stage (`STAGE_SAU = \{\}`, `job.py:52-56`); màn `/run` gọi `POST /outline` rồi `POST /jobs stage=nodes`. Chỉ có prompt hoặc thiết kế, ingest không gọi: đọc trang lần hai C4, `cross-checker.cross-check`, `extractor.extract-edge`, `reader.classify-block`, `extractor.extract-claims`.

Bước	Agent và prompt	Nhóm việc	Vị trí
Mục lục	`reader.outline` v3	read_image	`kg/ingest/outline.py:479–575`; `serve.py:770–860`
Lệch trang	chương trình		`outline.py:128–227`
Đọc trang	`reader.page-scan` v3	read_image	`kg/ingest/pagescan.py:295–406`
Rút khái niệm	`extractor.extract-nodes` v4	generate_text	`kg/ingest/nodes.py:664–704`
Lọc	chương trình		`nodes.py:706–734`
Kiểm khái niệm	`verifier.verify-node` v1	judge	`nodes.py:297–424, 738–756`
Đếm chỗ bỏ sót	chương trình		`nodes.py:206–294`
Vector	(không prompt)	embed	`nodes.py:529–551, 763–820`
Lĩnh vực	`clusterer.cluster-concepts` v3	judge	`kg/ingest/domains.py:92–137`
Môn › Lĩnh vực	`clusterer.phan-cap` v4	judge	`domains.py:244–324`
Đồng nghĩa	`clusterer.dong-nghia` v1	judge	`domains.py:362–416`
Liên kết `nhac_den`	chương trình		`kg/ingest/wiki_graph.py:431–596`
Tách bài tập	chương trình		`kg/ingest/baitap.py`

Bước	Vị trí
Router `answerer.chat` v1	`kg/query/ask.py:555–577, 626–638`
Năm phép lint	`kg/query/lint.py:186–280`; `ask.py:640–645`
Hạt giống: cosine $\geq 0{,}50$, tối đa 5	`ask.py:40, 54, 218–227`
Đi hop tới 8 claim, trần `max_hops`	`ask.py:45, 242–279, 691–702`
Soạn câu trả lời `answerer.answer` v4	`ask.py:713–750`; `contract/prompts/answerer.answer.md:9–50`
Khớp cite với claim, grep trang, lùi về trang đầu	`ask.py:380–437`; `kg/query/kho.py:82–170`
Gỡ câu không nguồn, `not_found`	`ask.py:440–474, 753–760`
Bằng chứng mức 1, gợi ý học	`serve.py:496–500`; `memory_store.py:483–538`
Cắt hình theo câu hỏi `reader.find-figure`	`serve.py:342–431`

A.3 Hỏi đáp có nguồn

A.4 Chấm bài tập

A.5 Mức nắm và ngân hàng câu hỏi

A.6 Chỗ tài liệu lệch code

- `docs/FLOW.md` còn tả 15 route, chín stage và chuỗi B→F; code có 40 endpoint và bốn stage. Mục §8 về `/ask` đã cũ.
- `kg/harness/config.py:9` ghi khoá chỉ lấy từ biến môi trường; code đọc `keys.env` trước.
- `docs/specs/kg.md` ghi một người dùng, không xác thực, API không ghi `harness.yaml`; code đã có tài khoản, phiên và `POST /setup`.
- `kiem_tra.py:1236` và docstring đầu tệp ghi câu tải lên không qua cổng; từ quyết định D15, câu tải lên qua G2–G7.
- Thiết kế chuyển lõi hỏi đáp sang microsoft/graphrag chưa từng được làm.

Bước	Vị trí
Ngữ cảnh sách (tới trước trang đề, trần 30 000 ký tự)	kg/query/grade.py:46–84
Thang chấm verifier.exercise-rubric v5	grade.py:289–292
Kiểm thang chấm bằng chương trình _rubric_hop_le	grade.py:140–178
Kiểm thang chấm verifier.verify-rubric v5	grade.py:298–304
Trắc nghiệm so bằng chương trình	grade.py:20, 119–124, 227–248
Chấm verifier.grade-exercise v4	grade.py:310–317
Kiểm nhất quán _grade_hop_le (70, 40, 5 ký tự)	grade.py:183–224
Phiếu mù (TODO pha 2)	grade.py:318–321
Ghi kết quả, xét mức	grade.py:338–426; memory_store.py:326–341

Thành phần	Vị trí
Năm mức, bac_moi (không tụt, không nhảy, +1)	kg/api/memory_store.py:39, 312–323
Một bài một lần	memory_store.py:377–384, 402–410
Tự đặt mức, không qua bac_moi	memory_store.py:249–275
Bốn chỉ số	memory_store.py:413–429
Hướng học (Tập trung, 0,4 / 0,6, 8 khái niệm)	kg/api/huong_hoc.py:39–42, 71–138
Độ sáng 80/20	web/src/routes/graph/nhiet.ts:3–38
Ba đường vào, dự toán	kg/query/kiem_tra.py:355–436, 659–728, 1350–1460
Chuỗi cổng G1–G7, luật gộp	kg/query/cong.py:603–1311
46 tiêu chí, cờ da_hieu_chinh	kg/query/tieu_chi.json
Bộ câu vàng 110 câu	tools/cong_kiem_goldenset.json

Tài liệu tham khảo

[1] Rabin Banjade, Priti Oli, Mahmudul Islam Sajib, and Vasile Rus. Identifying gaps in students' explanations of code using LLMs. Accepted manuscript, NSF Public Access Repository, 2024. URL https://par.nsf.gov/biblio/10561388.

[2] Hamsa Bastani, Osbert Bastani, Alp Sungu, Haosen Ge, Özge Kabakçı, and Rei Mariman. Generative AI without guardrails can harm learning: Evidence from high school mathematics. *PNAS*, 122(26):e2422633122, 2025. doi: 10.1073/pnas.2422633122.

[3] John B. Biggs and Kevin F. Collis. *Evaluating the Quality of Learning: The SOLO Taxonomy*. Academic Press, 1982. doi: 10.1016/C2013-0-10375-3.

[4] Kiran Bisra, Qing Liu, John C. Nesbit, Farimah Salimi, and Philip H. Winne. Inducing self-explanation: A meta-analysis. *Educational Psychology Review*, 30(3):703–725, 2018. doi: 10.1007/s10648-018-9434-x.

[5] Bộ Giáo dục và Đào tạo. Công văn 8773/bgdĐt-gdtrh hướng dẫn biên soạn đề kiểm tra, 2010. 30/12/2010.

[6] Bộ Giáo dục và Đào tạo. Thông tư 22/2016/tt-bgdĐt sửa đổi quy định đánh giá học sinh tiểu học, 2016. 22/09/2016.

[7] Bộ Giáo dục và Đào tạo. Chương trình giáo dục phổ thông môn hoá học (ban hành kèm thông tư 32/2018/tt-bgdĐt), 2018.

[8] Bộ Giáo dục và Đào tạo. Chương trình giáo dục phổ thông môn vật lí (ban hành kèm thông tư 32/2018/tt-bgdĐt), 2018.

[9] Bộ Giáo dục và Đào tạo. Chương trình giáo dục phổ thông môn toán (ban hành kèm thông tư 32/2018/tt-bgdĐt), 2018.

[10] Bộ Giáo dục và Đào tạo. Công văn 7991/bgdĐt-gdtrh về thực hiện kiểm tra, đánh giá đối với cấp thcs, thpt, 2024. 17/12/2024.

[11] Bộ Giáo dục và Đào tạo. Quyết định 764/qĐ-bgdĐt ban hành cấu trúc định dạng đề thi kỳ thi tốt nghiệp trung học phổ thông từ năm 2025, 2024. 08/3/2024.

[12] Bộ Giáo dục và Đào tạo. Thông tư 24/2024/tt-bgdĐt ban hành quy chế thi tốt nghiệp trung học phổ thông, 2024. 24/12/2024.

[13] Adriana Caraeni, Alexander Scarlatos, and Andrew Lan. Evaluating GPT-4 at grading handwritten solutions in math exams. In *LAK 2025: 15th International Learning Analytics and Knowledge Conference*, 2025.

[14] Penghe Chen, Yu Lu, Vincent W. Zheng, and Yang Pian. Prerequisite-driven deep knowledge tracing. In *IEEE ICDM*, pages 39–48, 2018. doi: 10.1109/ICDM.2018.00019.

[15] Zhongzhou Chen and Tong Wan. Grading explanations of problem-solving process and generating feedback using large language models at human-level accuracy. *Physical Review Physics Education Research*, 21(1):010126, 2025. doi: 10.1103/PhysRevPhysEducRes.21.010126. URL https://par.nsf.gov/biblio/10580008.

[16] Michelene T. H. Chi and Ruth Wylie. The icap framework: Linking cognitive engagement to active learning outcomes. *Educational Psychologist*, 49(4):219–243, 2014. doi: 10.1080/00461520.2014.965823.

[17] Bryan R Christ, Jonathan Kropko, and Thomas Hartvigsen. MATHWELL: Generating educational math word problems using teacher annotations. In *Findings of EMNLP 2024*, pages 11914–11938, 2024. doi: 10.18653/v1/2024.findings-emnlp.696.

[18] Albert T. Corbett and John R. Anderson. Knowledge tracing: Modeling the acquisition of procedural knowledge. *User Modeling and User-Adapted Interaction*, 4(4):253–278, 1995. doi: 10.1007/BF01099821.

[19] Nico Daheim, Jakub Macina, Manu Kapur, Iryna Gurevych, and Mrinmaya Sachan. Stepwise verification and remediation of student reasoning errors with large language model tutors, 2024.

[20] Shehzaad Dhuliawala, Mojtaba Komeili, Jing Xu, Roberta Raileanu, Xian Li, Asli Celikyilmaz, and Jason Weston. Chain-of-verification reduces hallucination in large language models. In *Findings of ACL 2024*, pages 3563–3578, 2024. doi: 10.18653/v1/2024.findings-acl.212.

[21] Steven M. Downing. The effects of violating standard item writing principles on tests and students. *Advances in Health Sciences Education*, 10:133–143, 2005. PMID 16078098.

[22] Darren Edge, Ha Trinh, Newman Cheng, Joshua Bradley, Alex Chao, Apurva Mody, Steven Truitt, and Jonathan Larson. From local to global: A graph RAG approach to query-focused summarization, 2024. URL `https://arxiv.org/abs/2404.16130`.

[23] Chenrui Fan et al. Missing premise exacerbates overthinking: Are reasoning models losing critical thinking skill?, 2025.

[24] Tianyu Gao, Howard Yen, Jiatong Yu, and Danqi Chen. Enabling large language models to generate text with citations. In *Proceedings of EMNLP 2023*, 2023. URL `https://arxiv.org/abs/2305.14627`.

[25] Thomas M. Haladyna, Steven M. Downing, and Michael C. Rodriguez. A review of multiple-choice item-writing guidelines for classroom assessment. *Applied Measurement in Education*, 15(3):309–333, 2002. doi: 10.1207/S15324818AME1503_5.

[26] Jie Huang, Xinyun Chen, Swaroop Mishra, Huaixiu Steven Zheng, Adams Wei Yu, Xinying Song, and Denny Zhou. Large language models cannot self-correct reasoning yet. In *ICLR*, 2024.

[27] Jaehun Jung, Faeze Brahman, and Yejin Choi. Trust or escalate: LLM judges with provable guarantees for human agreement, 2024.

[28] Sean H. K. Kang, Kathleen B. McDermott, and Henry L. Roediger. Test format and corrective feedback modify the effect of testing on long-term retention. *European Journal of Cognitive Psychology*, 19(4-5):528–558, 2007. doi: 10.1080/09541440601056620.

[29] Mohammad Khajah, Robert V. Lindsey, and Michael C. Mozer. How deep is knowledge tracing?, 2016.

[30] Seungone Kim, Jamin Shin, Yejin Cho, Joel Jang, Shayne Longpre, Hwaran Lee, Sangdoo Yun, Seongjin Shin, Sungdong Kim, James Thorne, and Minjoon Seo. Prometheus: Inducing fine-grained evaluation capability in language models. In *International Conference on Learning Representations (ICLR 2024)*, 2024.

[31] Avraham N. Kluger and Angelo DeNisi. The effects of feedback interventions on performance: A historical review, a meta-analysis, and a preliminary feedback intervention theory. *Psychological Bulletin*, 119(2):254–284, 1996. doi: 10.1037/0033-2909.119.2.254.

[32] Gerd Kortemeyer, Julian Nöhl, and Daria Onishchuk. Grading assistance for a handwritten thermodynamics exam using artificial intelligence: An exploratory study, 2024.

[33] David R. Krathwohl. A revision of bloom's taxonomy: An overview. *Theory Into Practice*, 41(4): 212–218, 2002. doi: 10.1207/s15430421tip4104_2.

[34] Michael Krumdick et al. No free labels: Limitations of LLM-as-a-judge without human grounding, 2025.

[35] Andreas Lachner, Leonie Jacob, and Vincent Hoogerheide. Learning by writing explanations: Is explaining to a fictitious student more effective than self-explaining? *Learning and Instruction*, 74: 101438, 2021. doi: 10.1016/j.learninstruc.2020.101438.

[36] Gyeong-Geon Lee, Ehsan Latif, Xuansheng Wu, Ninghao Liu, and Xiaoming Zhai. Applying large language models and chain-of-thought for automatic scoring. *Computers and Education: Artificial Intelligence*, 6:100213, 2024.

[37] Hunter Lightman, Vineet Kosaraju, Yura Burda, Harri Edwards, Bowen Baker, Teddy Lee, Jan Leike, John Schulman, Ilya Sutskever, and Karl Cobbe. Let's verify step by step, 2023.

[38] Thang Luong, Dawsen Hwang, Hoang H. Nguyen, et al. Towards robust mathematical reasoning. In *Proceedings of EMNLP 2025*, 2025.

[39] Jingyuan Ma et al. Large language models are unconscious of unreasonability in math problems, 2024.

[40] Steven Moore et al. Assessing the quality of multiple-choice questions using GPT-4 and rule-based methods, 2023. EC-TEL 2023.

[41] Steven Moore et al. An automatic question usability evaluation toolkit, 2024. AIED 2024.

[42] Jialin Ouyang. TreeCut: A synthetic unanswerable math word problem dataset for LLM hallucination evaluation, 2025.

[43] Miguel A. Paniagua and Kimberly A. Swygert. *Constructing Written Test Questions for the Basic and Clinical Sciences*. National Board of Medical Examiners, 4 edition, 2016.

[44] Arjun Panickssery, Samuel R. Bowman, and Shi Feng. LLM evaluators recognize and favor their own generations. In *NeurIPS 37*, 2024. doi: 10.52202/079017-2197.

[45] Hannah Rashkin, Vitaly Nikolaev, Matthew Lamm, Lora Aroyo, Michael Collins, Dipanjan Das, Slav Petrov, Gaurav Singh Tomar, Iulia Turc, and David Reitter. Measuring attribution in natural language generation models. *Computational Linguistics*, 2023. URL `https://arxiv.org/abs/2112.12870`.

[46] Englevert P. Reyes et al. Feynman technique as a heutagogical learning strategy for independent and remote learning. *Recoletos Multidisciplinary Research Journal*, 9(2):1–13, 2021.

[47] Henry L. Roediger and Jeffrey D. Karpicke. Test-enhanced learning: Taking memory tests improves long-term retention. *Psychological Science*, 17(3):249–255, 2006. doi: 10.1111/j.1467-9280.2006.01693.x.

[48] Doug Rohrer, Robert F. Dedrick, Marissa K. Hartwig, and Chi-Ngai Cheung. A randomized controlled trial of interleaved mathematics practice. *Journal of Educational Psychology*, 112(1): 40–52, 2020. doi: 10.1037/edu0000367.

[49] YuHong Sun et al. Benchmarking hallucination in large language models based on unanswerable math word problem, 2024.

[50] Marie Tarrant and James Ware. Impact of item-writing flaws in multiple-choice questions on student achievement in high-stakes nursing assessments. *Medical Education*, 42:198–206, 2008. PMID 18230093.

[51] Fabienne M. Van der Kleij, Remco C. W. Feskens, and Theo J. H. M. Eggen. Effects of feedback in a computer-based learning environment on students' learning outcomes: A meta-analysis. *Review of Educational Research*, 85(4):475–511, 2015. doi: 10.3102/0034654314564881.

[52] Pat Verga, Sebastian Hofstätter, Sophia Althammer, et al. Replacing judges with juries: Evaluating LLM generations with a panel of diverse models, 2024.

[53] Yun Wang, Zhaojun Ding, Xuansheng Wu, Siyue Sun, Ninghao Liu, and Xiaoming Zhai. AutoSCORE: Enhancing automated scoring with multi-agent large language models via structured component recognition, 2025. AAAI 2026 [chưa kiểm].

[54] Norman L. Webb. Criteria for alignment of expectations and assessments in mathematics and science education. Research Monograph 6, National Institute for Science Education, 1997. ERIC ED414305.

[55] Benedikt Wisniewski, Klaus Zierer, and John Hattie. The power of feedback revisited: A meta-analysis of educational feedback research. *Frontiers in Psychology*, 10:3087, 2020. doi: 10.3389/fpsyg.2019.03087.

[56] Jörg Wittwer and Alexander Renkl. Why instructional explanations often do not work: A framework for understanding the effectiveness of instructional explanations. *Educational Psychologist*, 43(1), 2008. doi: 10.1080/00461520701756420.

[57] Taisei Yamauchi, Brendan Flanagan, Yiling Dai, Toshihiro Kita, and Hiroaki Ogata. A rubric-based LLM automatic grading of mathematical reasoning in self-explained answers. In *ICLEA 2025: 1st International Conference on Learning Evidence and Analytics*, 2025. URL `https://library.apsce.net/index.php/ICLEA/article/view/5504`.

[58] Chunliang Yang, Liang Luo, Miguel A. Vadillo, Rongjun Yu, and David R. Shanks. Testing (quizzing) boosts classroom learning: A systematic and meta-analytic review. *Psychological Bulletin*, 147(4):399–435, 2021. doi: 10.1037/bul0000309.

[59] Zhenru Zhang, Chujie Zheng, Yangzhen Wu, Beichen Zhang, Runji Lin, Bowen Yu, Dayiheng Liu, Jingren Zhou, and Junyang Lin. The lessons of developing process reward models in mathematical reasoning, 2025.

[60] Yulai Zhao, Haolin Liu, Dian Yu, Sunyuan Kung, Meijia Chen, Haitao Mi, and Dong Yu. One token to fool LLM-as-a-judge, 2025.

[61] Chujie Zheng, Zhenru Zhang, Beichen Zhang, Runji Lin, Keming Lu, Bowen Yu, Dayiheng Liu, Jingren Zhou, and Junyang Lin. ProcessBench: Identifying process errors in mathematical reasoning. In *Proceedings of ACL 2025*, 2025.

[62] Lianmin Zheng, Wei-Lin Chiang, Ying Sheng, et al. Judging LLM-as-a-judge with MT-bench and chatbot arena. In *NeurIPS 36, Datasets and Benchmarks Track*, 2023.